



석사학위 논문 계획서

전 공 : 데이터사이언스/인공지능 전공

학 번 : A66050

성 명 : 여 윤 기

논 문 제 목 : Grad-CAM(Class Activation Map) 활용한 다양한 표면 종류에 대한 균열 이미지
탐지모델 연구

첨부 : 논문 구성 1부

논문 지도교수 : 최 준 석 교수 (인)

A handwritten signature in black ink, likely belonging to Professor Choi Jun-seok, written over the text "논문 지도교수 : 최 준 석 교수 (인)".

2024 년 1 월 25 일

논문 제출자 : 여 윤 기 (인)

A handwritten signature in black ink, likely belonging to Ye Eun-gi, written over the text "논문 제출자 : 여 윤 기 (인)".

정보통신대학원장 귀하

[논문 구성]

제 1 장 서론 3

제 1 절 연구배경 및 필요성

제 2 절 연구 목적

제 3 절 논문 구성

제 2 장 관련 연구 4

제 1 절 컴퓨터 비전 활용한 균열 탐지 기술

제 2 절 딥러닝 기반 이미지 분류 기법

(1) VGG모델

(2) ResNet

(3) EfficientNet

제 3 장 제안 방법5

제 1 절 실험 데이터셋 구성

제 2 절 데이터 전처리

제 3 절 설명가능한 인공지능(XAI) 적용 방법

(1) 설명가능한 인공지능(XAI) 소개

(2) Grad-CAM 알고리즘

제 4 장 연구 실험 및 평가7

제 5 장 결론 및 한계점9

참고문헌

제 1 장 서 론

제 1 절 연구배경 및 필요성

구조물의 안전성과 수명을 결정하는 중요한 요소 중 하나는 표면의 균열입니다. 균열은 건물, 교량, 도로, 수송관, 선체표면 등에 이르기까지 사회 기반시설의 안전성에 영향을 주는 큰 요소 중 하나입니다. 이러한 균열에 대한 기존 안전점검은 경험과 기술을 갖춘 검사자가 육안으로 시설물의 손상이나 결함을 식별하는 것으로 수행되고 있으며 이와 같은 점검방식은 검사자의 주관성과 숙련도, 피로도에 따라 검사의 신뢰도에 큰 영향을 미칠 뿐 아니라 시간과 비용이 많이 소요됩니다.

최근 컴퓨터 비전과 딥 러닝 기술의 발전으로 이미지 데이터를 활용한 균열 탐지 인공지능 모델 개발이 가능해졌고 이러한 기술은 수동 검사보다 빠르고 정확할 수 있으며, 대규모 구조물 검사에 효과적입니다. 실제 현장에서 구조물의 표면은 콘크리트, 아스팔트, 금속 등 다양한 재료로 이루어져 있습니다. 각 재료의 표면 특성은 매우 다르기 때문에, 이들에 효과적으로 대응할 수 있는 범용적인 균열 분류 모델 개발이 필요하며, 개발된 인공지능 모델의 예측결과는 모델의 예측 근거가 인간에게 충분히 설명되어 모델의 신뢰성을 더욱 향상시킬수 있어야 합니다.

제 2 절 연구목적

일반적으로 Grad-CAM(Gradient-weighted Class Activation Mapping) 알고리즘은 딥 러닝 모델이 특정 결정을 내린 이유를 시각화하기 위해 사용됩니다. 이를 통해 개발한 인공지능 균열 탐지 모델이 탐지 과정에서 균열을 어떻게 탐지하고 있는지 시각화하고, 모델의 정확성과 신뢰성을 향상시킬 수 있습니다. 본 논문에서는 Grad-CAM 알고리즘을 균열 탐지 모델에 적용함으로써 아래 3가지를 주요 목적으로 연구하고자 합니다.

1. 모델 신뢰성 향상 : Grad-CAM을 기반으로 한 XAI 모델을 균열 이미지 탐지모델에 적용시켜 인공지능 모델의 예측결과에 대한 신뢰성 향상
2. 다양한 균열 탐지모델의 Grad-CAM 적용결과 비교 : 선행연구에서 일반적으로 활용된 다양한 균열 탐지모델에 대해 Grad-CAM 알고리즘을 적용시킨 결과를 시각적으로 비교
3. 균열 탐지모델의 범용성 검증 : 다양한 종류의 표면과 환경 조건에서 모델의 효과성을 검증하고 이를 통해 모델이 실제 세계의 다양한 표면환경에 활용될 수 있는지를 평가

제 3 절 논문 구성

논문의 전체적인 구성 및 각 장의 주요 내용을 개요화하여 제시 예정입니다.

제 2 장 관련 연구

제 1 절 컴퓨터 비전을 활용한 균열 탐지 기술

초기 컴퓨터 비전을 활용한 균열 탐지 연구는 주로 간단한 이미지 처리 기술에 의존했습니다. 예를 들어, 임계값(thresholding), 엣지 검출(edge detection), 그리고 모폴로지(morphology) 연산 등과 같은 방법이 일반적으로 사용되었습니다. 이후 균열의 특성을 파악하기 위해 다양한 피처(Feature) 기반 방법이 도입되었습니다. 이는 균열의 형태, 방향성, 크기 등을 분석하여 균열을 탐지하는 방식으로 지역 이진 패턴(Local Binary Patterns, LBP), Gabor 필터, SIFT(Scale-Invariant Feature Transform) 기법 등이 개발되었습니다.

최근에는 딥러닝, 특히 컨볼루션 신경망(CNN) 기반 방법이 대부분의 균열 탐지 연구에서 활용됩니다. 이러한 방법은 자동으로 이미지 내 특징을 학습하고, 복잡한 이미지에서도 높은 정확도로 균열을 탐지할 수 있는 장점이 있습니다. CNN을 활용한 연구들은 기존 전통적 연구 기법보다 우수한 성능을 보여주었으며 균열 탐지에 효과적임이 선행연구를 통해 입증되었습니다. 이미지 분류를 위해 고안된 대표적인 딥러닝 모델들은 제2절에서 보다 상세히 서술하겠습니다. 기존에 수행된 여러 선행연구들에도 불구하고 다양한 조명 상태, 날씨 변화, 배경 잡음 등 복잡한 환경에서의 정확한 균열 탐지가 여전히 도전적인 문제로 남아있으며, 다양한 표면 재질에 대한 적용 가능성 등을 개선할 필요가 있습니다.

제 2 절 딥러닝 기반 이미지 분류 기법

앞서 언급한 CNN 기반의 균열 탐지 연구에서 대표적으로 활용된 모델들은 크게 아래 3가지 모델이 있으며, 각 모델의 세부적인 특성에 대해 언급하였습니다.

1. VGG : VGG의 주요 특징은 그 구조의 단순성과 깊이에 있습니다. 모델은 여러 개의 작은 (3x3) 컨볼루션 필터를 사용하고, 이를 여러 계층에 걸쳐 쌓는 방식으로 구성됩니다.
2. ResNet : ResNet의 핵심은 "잔차 블록(Residual Block)"입니다. 이는 입력을 네트워크의 다음 층으로 직접 전달하는 '스킵 연결(skip connection)'을 포함합니다. 이러한 구조는 깊은 네트워크에서 발생할 수 있는 "소실된 그래디언트(Vanishing Gradient)" 문제를 효과적으로 해결합니다.
3. EfficientNet : EfficientNet은 Google AI 연구팀에 의해 개발되었습니다. 이 모델은 기존 CNN 모델의 효율성을 향상시키는 것을 목표로 합니다. EfficientNet에서는 네트워크의 깊이(depth), 너비(width), 그리고 해상도(resolution)를 동시에 조정하여


네트워크의 성능을 향상시킵니다. EfficientNet은 이를 통해 이전 모델들에 비해 상대적으로 적은 계산 자원과 메모리를 사용하면서도 뛰어난 성능을 제공합니다.

제 3 장 제 안 방 법

제 1 절 실험 데이터셋 구성

다양한 표면과 환경에 모두 적용 가능한 균열 탐지 모델을 구성하기 위해서 여러 표면과 환경에서 추출한 균열 데이터셋을 활용하였습니다. 이를 위해 수집한 실험 데이터셋은 아래와 같습니다.

1. 가로*세로 448*448 pixel인 포장도로와 콘크리트 구조물의 표면 균열 이미지 9,887장 및 정상 이미지 1,411장(https://github.com/khanhha/crack_segmentation#Dataset)
2. 54개의 교량 갑판, 104개의 포장도로, 72개의 벽에서 추출한 균열 이미지 및 정상이미지 약 56,000장. 각 이미지는 그림자와 거칠기, 구멍 및 파편 등 다양한 잡음(noise)를 포함하고 있다. (https://digitalcommons.usu.edu/all_datasets/48/)
3. 가로*세로 227*227 pixel인 다양한 콘크리트 표면의 균열 이미지 20,000장과 정상 이미지 20,000장(<https://www.kaggle.com/datasets/arunrk7/surface-crack-detection>)
4. 가로*세로 128*128pixel인 조명, 그림자 등이 포함된 건물의 균열 이미지 991장, 정상 이미지 1,264장(<https://github.com/nargundshreyas/Concrete-Crack-Detection>)



< 데이터셋 구조(Positive : 균열 이미지 / Negative : 정상 이미지) >

제 2 절 데이터 전처리

데이터 전처리는 모델의 성능에 큰 영향을 미치므로, 전처리 과정을 정확하고 체계적으로 진행하는 것이 필수적입니다. 일반적으로 모델 성능 향상과 효과적 학습을 위해 아래와 같은 데이터 전처리 기법들이 활용될 수 있습니다.

1. 데이터 증강(Data Augmentation) : 수집한 데이터셋 내 이미지에 대해 회전, 반전, 확대/축소, 밝기 조정 등을 적용시킬 수 있으며, 이를 통해 모델이 더 다양한 이미지의 특성을 학습합니다.
2. 노이즈 제거 : 이미지에서 불필요한 노이즈를 제거하고, 명암 대비, 선명도 등을 조절하여 균열 부분이 더 명확하게 드러나도록 전처리를 수행합니다. 이때 필터링, Edge 강화 등의 기법이 활용될 수 있습니다.
3. 라벨링 및 데이터 분할 : 균열 이미지와 정상 이미지를 정확히 라벨링하여 구분하고 전체 데이터셋을 Train, Validation, Test set 으로 분할합니다. 데이터의 70-80%를 모델 학습에, 학습과정에서 사용되지 않은 나머지 데이터셋을 모델 검증 및 테스트에 사용합니다.

제 3 절 설명가능한 인공지능(XAI) 적용 방법

(1) 설명가능한 인공지능 소개

설명가능한 인공지능(Explainable Artificial Intelligence, XAI)은 인공지능(AI)의 결정 과정을 사람이 이해할 수 있도록 만드는 연구 분야입니다. XAI의 주된 목적은 AI의 투명성과 신뢰성을 향상시키는 것입니다. 이를 통해 XAI는 사용자가 AI의 결정을 신뢰할 수 있도록 도와주고 사용자가 이해하고 예측할 수 있어 AI모델이 더 널리 수용될 수 있습니다. 또한 모델의 결정 과정을 이해함으로써 오류를 발견하고 개선하여 모델의 정확성과 효율성을 더욱 향상시킬 수 있습니다.

(2) Grad-CAM 알고리즘

Grad-CAM(Gradient-weighted Class Activation Mapping) 알고리즘은 CNN 모델의 결정을 시각화하는 방법 중 하나로, 특히 이미지 인식 분야에서 유용합니다. Grad-CAM은 일반적으로 CNN의 마지막 컨볼루션 레이어를 타겟으로 하여 특정 클래스에 대한 출력의 그래디언트를 계산합니다. 이 그래디언트는 타겟 레이어의 특징 맵에 대한 중요도를 나타내는데, 계산된 그래디언트를 이용하여 각 특징 맵의 가중치를 계산합니다. 이 가중치들을 특징 맵에 곱하고 평균을 내어 heatmap을 생성합니다.

이러한 원리로 생성된 heatmap을 원본 이미지와 겹쳐서 시각화함으로써 모델이 특정 클래스를 인식하는데 어떤 영역을 중요하게 고려하였는지를 나타내줍니다. 따라서 Grad-CAM을 통해 사용자는 모델이 '왜'와 '어떻게' 특정 결정을 내렸는지 시각적으로 이해할 수 있으며 잘못된 예측의 원인을 분석하고, 모델을 개선하는 데 도움이 됩니다.

제 4 장 연구 실험 및 평가

본격적인 연구 실험에 앞서, 모델 학습을 위한 환경은 아래와 같이 구성할 예정입니다.

1. 서강대학교 인공지능학과 GPU 클러스터 활용
 - a. CPU : 64bit 64 core / 128 Thread 2.0Ghz 256M chash * 2EA
 - b. Memory : 1024GB(64GB * 16EA)
 - c. SSD : 2.5inch 7.64TB SSD * 6EA
 - d. GPU : NVIDIA A100 80GB Pcie * 8EA
2. 구글 Colab Pro에서 할당되는 GPU 활용

앞서 설명한 Grad-CAM 알고리즘은 다양한 모델에 적용이 가능하며 구현이 상대적으로 간단하다는 장점이 있어, 본 연구에서는 다양한 딥러닝 모델을 수집한 각각의 데이터셋 및 통합 데이터셋으로 학습시킨 후 평가지표를 활용하여 학습결과를 모델별로 비교분석하고 Grad-CAM을 적용한 결과를 시각화할 계획입니다. 모델 평가를 위한 세부 평가지표는 Confusion Matrix를 활용하여 다음과 같이 설정할 예정입니다.

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

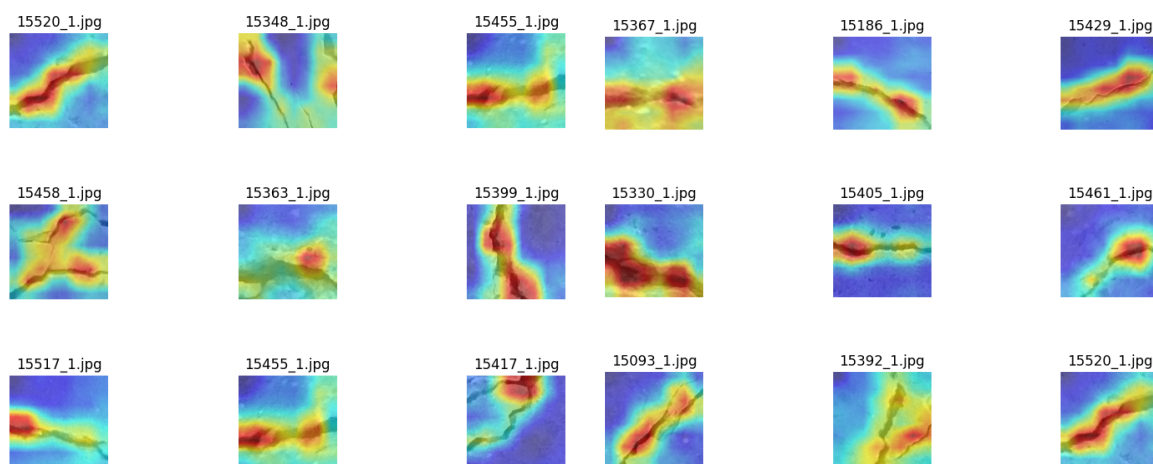
< Confusion Matrix 예시 >

1. 모델의 정확도(Accuracy) = $(TP + TN) / (TP + FP + FN + TN)$
2. F1-Score : $2 * (Recall * Precision) / (Recall + Precision)$

Model	Dataset No.1 (%)	Dataset No.2 (%)	Dataset No.3 (%)	Dataset No.4 (%)	Combined Dataset (%)
VGG16					
VGG19					
ResNet50					
ResNet101					
ResNet152					
EfficientNetB0					
EfficientNetB2					
EfficientNetB4					

< 각각의 데이터셋별 각 모델의 정확도 비교(예시) >

Grad-CAM 적용결과 실험을 위해 수집한 전체 데이터셋 중 약 1,000장의 균열/정상 이미지를 일부 샘플데이터셋으로 분리하고, 사전학습된 ResNet50 모델을 샘플데이터셋으로 Transfer Learning 하였습니다. 그 결과 아래 사진과 같이 이미지 내 균열 부분을 따라 heatmap으로 표시되었음을 확인하였고, 추가적인 학습 및 데이터 전처리 작업을 수행한다면 heatmap이 균열을 따라 보다 정확하게 나타낼 수 있을 것으로 판단하였습니다.



< 샘플데이터셋 활용한 Grad-CAM 적용결과 >

제 5 장 결론 및 한계점

제 4장 연구 실험 및 평가 결과를 바탕으로 연구 결론, 연구의 중요한 Contribution 내용, 그리고 연구의 한계점 및 향후 추가적인 연구 방향에 대해 서술할 계획입니다.

참고문헌

- [1] 최훈, 박세연, 이한별, 송연주, 김형훈. (2020). 균열로 인한 사고를 방지하기 위한 선체 균열탐지 로봇 개발. 한국정보처리학회 학술대회논문집, 27(2), 996-999.
- [2] 남우석, 정현준, 박경한, 김철민, 김규선. (2022). 콘크리트 교량 상태평가를 위한 딥러닝 기반 손상 탐지 프로토타입 개발. 대한토목학회논문집, 42(1), 107-116.
- [3] 지홍근, 김지나, 황시정, 김도건, 박은일, 김영석, 류승기. (2021). 자동화 균열 탐지 시스템을 위한 딥러닝 모델에 관한 연구. 정보처리학회논문지. 소프트웨어 및 데이터 공학, 10(5), 161-168.
- [4] 임희경 and 김승언. (2022). 설명가능한 인공지능(explainable AI, XAI)의 필요성과 연구동향. 정보기술융합공학논문지, 12(1), 51-57.
- [5] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. Proceedings of the IEEE International Conference on Computer Vision (ICCV), 618-626. <https://doi.org/10.1109/ICCV.2017.74>